软件系统优化A3实验报告

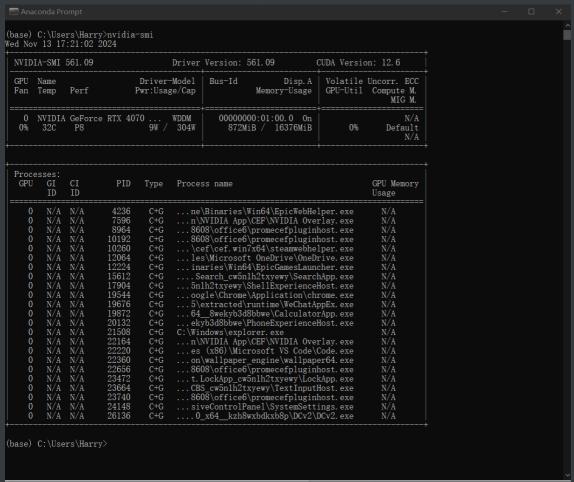
环境配置

实验平台

本次的实验我进行的平台是台式机,CPU为*Intel 13600kf*,GPU为*NVIDIA GeForce RTX* 4070 Ti SUPE。

cuda配置

由于之前进行过大模型的本地部署,因此安装过cuda,cuda版本如下

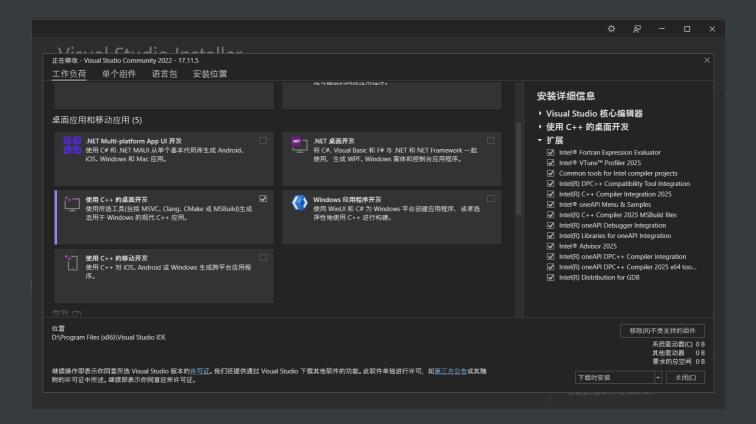


安装opeapi-base-toolkit和one-api-for-nvidia-gpus

下载后根据GUI完成安装

□ intel-oneapi-base-toolkit-2025.0.0.8... 2024/11/12 23:56 文件夹
□ intel-oneapi-base-toolkit-2025.0.0.8... 2024/11/12 23:53 应用程序 2,967,535...
□ oneapi-for-nvidia-gpus-2025.0.0-cud... 2024/11/12 23:54 Windows Install... 952 KB

安装Visual Studio并安装桌面c++开发环境



完成配置

完成上述的环境安装和配置后,我们运行环境配置脚本

```
...n\NVIDIA App\CEF\NVIDIA Overlay.exe
...8608\office6\promecefpluginhost.exe
...8608\office6\promecefpluginhost.exe
...\cef\cef.win7x64\steamwebhelper.exe
...les\Microsoft OneDrive\OneDrive.exe
...inaries\Win64\EpicGamesLauncher.exe
....Search_cw5nlh2txyewy\SearchApp.exe
...5nlh2txyewy\ShellExperienceHost.exe
...oogle\Chrome\Application\chrome.exe
...5\extracted\runtime\WeChatAppEx.exe
...64__8wekyb3d8bbwe\CalculatorApp.exe
...ekyb3d8bbwe\PhoneExperienceHost.exe
...exp. Romer of the control of t
                                                                             8964
10192
10260
                                                                                                                                                                                                                                                                          C+G
C+G
                                                                                                                                                                                                                                                                             C+G
                                                                                                                                                                                                12064
12224
15612
                                                                                                                                                                                                                                                                             C+G
                                                                                                                                                                                              17904
19544
19676
                                                                                                                                                                                                                                                                           C+G
C+G
                                                                                                                                                                                            19872
20132
21508
22164
22220
22360
22656
23472
23664
23740
24148
                                                                                                                                                                                                                                                                             C+G
                                                                                                                                                                                                                                                                                                                           ...64__Swekyb3dSbbwe\CalculatorApp.exe
...ekyb3dSbbwe\PhoneExperienceHost.exe
C:\Windows\explorer.exe
...n\NYIDIA App\CEF\NYIDIA Overlay.exe
...es (x86)\Microsoft VS Code\Code.exe
...on\wallpaper_engine\wallpaper64.exe
...8608\office6\promecefpluginhost.exe
...LockApp_cw5n1h2txyewy\LockApp.exe
...CBS_cw5n1h2txyewy\TextInputHost.exe
...8608\office6\promecefpluginhost.exe
...siveControlPanel\SystemSettings.exe
...0_x64__kzh8wxbdkxb8p\DCv2\DCv2.exe
                                                                                                                                                                                                                                                                          C+G
C+G
                                                                                                                                                                                                                                                                             C+G
                                                                                                                                                                                                                                                                             C+G
                                                                                                                                                                                                                                                                             C+G
                                                                                                                                                                                                                                                                           C+G
C+G
                                                                                                                                                                                                                                                                             C+G
(base) C:\Users\Harry>"C:\Program Files (x86)\Intel\oneAPI\setvars.bat"
:: initializing oneAPI environment...
Initializing Visual Studio command-line environment...
Visual Studio version 17.11.5 environment configured.
"D:\Program Files (x86)\Visual Studio IDE\"
Visual Studio command-line environment initialized for: 'x64'
                        advisor -- latest
compiler -- latest
dal -- latest
                        debugger -- latest
dev-utilities -- l
                       dnnl -- latest
dpcpp-ct -- latest
dpl -- latest
ipp -- latest
                        ippcp -- latest
mkl -- latest
                        ocloc -- latest
pti -- latest
tbb -- latest
                        umf -- latest
vtune -- latest
                          oneAPI environment initialized ::
   (base) C:\Users\Harry>
```

成功运行

我们来编译并运行一下测试代码

程序成功选择了 **NVIDIA GeForce RTX 4070 Ti SUPER** 作为计算设备,并且通过 CUDA 后端进行计算。

Part 1 实验课练习

任务1

学习**basic_parafor.cpp**代码,了解主机内存与设备内存(CPU、GPU)的分配、拷贝、释放等函数的应用,以及并行计算的 parallel_for 函数的使用

我们首先可以编译并运行一下basic_parafor.cpp

USM官方文档

Kinds of USM

shared

USM builds upon Unified Addressing to define a shared address space where pointer values in this space always refer to the same location in memory. USM defines three types of memory allocations: host, device, and shared.

```
The following enum is used to refer to the different types of allocations inside of a SYCL program:

namespace sycl::usm {
enum class alloc : /* unspecified */ {
host,
device,
shared,
unknown
};
} // namespace sycl::usm

USM allocation type Description

host Allocations in host memory that are accessible by a device (in addition to the host).

device Allocations in device memory that are not accessible by the host.
```

Allocations in shared memory that are accessible by both host and device.

我们可以看到,官方将USM即Undefined Shared memory分为三种:

1. host

主机内存分配,这些内存可以被 **设备** 访问(除了主机本身之外)。 这种类型的内存分配是在主机(CPU)内存中进行的,但它同时允许设备(例如 GPU) 访问这块内存。这种内存常用于主机和设备之间的数据传输或共享。

2. device

设备内存分配,这些内存 不能 被主机访问。

这种内存分配发生在设备内存中,例如 GPU 的显存,主机程序无法直接访问这些内存,只有设备(GPU 或其他加速器)能访问。设备内存通常用于存储需要在设备上处理的数据。

3. shared

共享内存分配,这些内存可以被 主机和设备 共同访问。

共享内存是一种特殊的内存类型,既能在主机(CPU)上使用,也能在设备(如 GPU) 上使用。这种内存类型适用于主机和设备之间需要频繁交换数据的场景。

USM的分配

首先是分配主机内存的 sycl::malloc_host

我们可以查看**SYCL官方文档**

sycl::malloc_host

我们可以看到**basic_parafor.cpp**使用的是 **sycl::malloc_host** with **sycl::queue** 中的 T* sycl::malloc_host

对于参数、我们可以查看Parameters

Parameters	
alignment	Alignment of allocated data.
numBytes	Allocation size in bytes.
count	Number of elements.
syclDevice	See sycl::device.
syclQueue	See sycl::queue.
syclContext	See sycl::context.
propList	Optional property list.

使用 T* sycl::malloc_host 来分配内存需要我们给定两个必须参数,一个是 count ,用于给定元素的数量,另一个是 syclQueue 即分配内存的 SYCL 队列。

对于 syclQueu ,我们来继续查看文档

sycl::queue

class queue;

The sycl::queue connect a host program to a single device. Programs submit tasks to a device via the sycl::queue and may monitor the sycl::queue for completion. A program initiates the task by submitting a command group to a sycl::queue. The command group defines a kernel function, the prerequisites to execute the kernel function, and an invocation of the kernel function on an index space. After submitting the command group, a program may use the sycl::queue to monitor the completion of the task for completion and errors. A sycl::queue can wait for all command groups that it has submitted by calling wait or wait_and_throw.

可以看到 sycl::queue 用于连接一个主机程序和一个单独的设备(实验中我们连接了GPU),我们可以通过其来进行提交命令组、监控任务完成、同步与异步。

因此通过basic_parafor.cpp中的

```
int *host_mem = mallohc_host<int>(N, my_gpu_queue);
```

我们为GPU在主机内存中分配了N个int型大小的空间并获得了其指针。

sycl::malloc_device

参数与使用方法和 sycl::malloc_host 相同

因此我们通过

```
int *device_mem = malloc_device<int>(N, my_gpu_queue);
```

为GPU在GPU内存中分配了N个int型大小的空间并获得了其指针。需要注意的其分配的内存只能由设备(本实验中为GPU)直接访问,而不能直接由主机程序访问。

USM的拷贝

官方文档如下

```
memcpy

void memcpy(void* dest, const void* src, size_t numBytes);

Copies numBytes of data from the pointer src to the pointer dest. The dest and src parameters must each either be a host pointer or a pointer within a USM allocation that is accessible on the handler's device. If a pointer is to a USM allocation, that allocation must have been created from the same context as the handler's queue.

For more detail on USM, please see USM Basic Concept.
```

可见该函数用于在USM拷贝内存,我们需给定参数 dest 和 src 指针,并给定拷贝数据的大小。

该函数在basic_parafor.cpp中使用如下

```
// Copy from host(CPU) to device(GPU)
my_gpu_queue.memcpy(device_mem, host_mem, N * sizeof(int)).wait();
```

这里的 wait 指的是等待拷贝完成后再继续执行接下来的代码。

```
wait

void wait();

Wait for the event and the command associated with it to complete.
```

如此我们将 host 内存中的内容拷贝到了 device 内存中。

USM的释放

官方文档如下

sycl::free

```
void sycl::free(void* ptr, const sycl::context& syclContext);
void sycl::free(void* ptr, const sycl::queue& syclQueue);
```

Frees an allocation. The memory pointed to by ptr must have been allocated using one of the USM allocation routines. syclContext must be the same sycl::context that was used to allocate the memory. The memory is freed without waiting for commands operating on it to be completed. If commands that use this memory are in-progress or are enqueued the behavior is undefined. In the second form the context is automatically extracted from the syclQueue that is passed in, as a convenience.

我们可以发现该函数有两种使用方式

一种是传入指定了内存分配时使用的上下文 syclContext & sycl::context

另一种是传入传入队列对象 syclQueue & sycl::queue

显然在basic_parafor.cpp中我们使用第二种

```
free(host_mem, my_gpu_queue);
free(device_mem, my_gpu_queue);
```

任务2

修改basic_parafor.cpp代码,将申请的内存空间修改为本机与设备共享内存空间。并思考主机内存和设备内存修改为共享内存空间的好处。

修改代码为共享内存空间

我们首先通过官方文档来看怎么来申请共享内存空间

sycl::malloc_shared

```
const sycl::property_list& propList = {});
template <typename T>
T* sycl::malloc_shared(size_t count,
                       const sycl::device& syclDevice,
                       const sycl::context& syclContext,
                       const sycl::property_list& propList = {});
void* sycl::malloc_shared(size_t numBytes,
                          const sycl::queue& syclQueue,
                          const sycl::property_list& propList = {});
template <typename T>
T* sycl::malloc_shared(size_t count,
                       const sycl::queue& syclQueue,
                       const sycl::property_list& propList = {});
void* sycl::aligned_alloc_shared(size_t alignment, size_t numBytes,
                                 const sycl::device& syclDevice,
                                 const sycl::context& syclContext,
                                 const sycl::property_list& propList =
{});
template <typename T>
T* sycl::aligned_alloc_shared(size_t alignment, size_t count,
                              const sycl::device& syclDevice,
                              const sycl::context& syclContext,
                              const sycl::property_list& propList =
{});
void* sycl::aligned_alloc_shared(size_t alignment, size_t numBytes,
                                 const sycl::queue& syclQueue,
                                 const sycl::property_list& propList =
{});
template <typename T>
```

Parameters	
(-1/	Alignment of allocated data
alignment	Alignment of allocated data.
numBytes	Allocation size in bytes.
count	Number of elements.
syclDevice	See sycl::device.
syclQueue	See sycl::queue.
syclContext	See sycl::context.
propList	Optional property list.

On successful USM shared allocation, these functions return a pointer to the newly allocated memory, which must eventually be deallocated with sycl::free in order to avoid a memory leak. If there are not enough resources to allocate the requested memory, these functions return nullptr.

When the allocation size is zero bytes (numBytes or count is zero), these functions behave in a manner consistent with C++ std::malloc. The value returned is unspecified in this case, and the returned pointer may not be used to access storage. If this pointer is not null, it must be passed to sycl::free to avoid a memory leak.

使用方法类似,我们只需要给定申请的元素类型、元素个数以及SYCL队列,同时我们也不必再对内存数据进行拷贝。注意最后需要释放内存。如此我们代码修改如下

```
#include <sycl/sycl.hpp>
#include <iostream>
using namespace sycl;

constexpr int N = 10;

int main() {
    queue my_gpu_queue(sycl::gpu_selector_v);

    std::cout << "Selected GPU device: " <<
        my_gpu_queue.get_device().get_info<info::device::name>() <<
"\n";</pre>
```

```
// 申请共享内存, 主机和设备共享此内存
    int *shared_mem = malloc_shared<int>(N, my_gpu_queue);
    for (int i = 0; i < N; i++) {
        shared_mem[i] = i;
    my_gpu_queue.submit([&](handler& h) {
       h.parallel_for(range{N}, [=](id<1> item) {
            shared_mem[item] *= 2;
       });
   });
    my_gpu_queue.wait();
    printf("\nData Result\n");
    for (int i = 0; i < N; i++) {
       printf("%d, ", shared_mem[i]);
    printf("\nTask Done!\n");
    free(shared_mem, my_gpu_queue);
    return 0;
}
```

成功完成修改

共享内存的好处

共享内存是主机和设备之间的一种高效数据交换机制,它的主要好处包括:

- 提高数据访问效率和减少延迟。
- 简化主机和设备之间的数据传输。
- 减少内存开销并优化内存使用。
- 提升并行计算性能。
- 增强设备资源的利用率。
- 简化数据管理和内存分配。

共享内存不仅适用于主机和设备之间的数据传输,还大大提高了计算性能,尤其是在需要并行 计算的场景中。

```
#include <sycl/sycl.hpp>
#include <iostream>
#include <chrono>
using namespace sycl;
constexpr int N = 10;
void test_malloc_host_device(queue& my_qpu_queue) {
    auto start = std::chrono::high_resolution_clock::now();
    int* host_mem = malloc_host<int>(N, my_gpu_queue);
    int* device_mem = malloc_device<int>(N, my_gpu_queue);
   // Init CPU data
    for (int i = 0; i < N; i++) {
        host_mem[i] = i;
   // Copy from host(CPU) to device(GPU)
    my_gpu_queue.memcpy(device_mem, host_mem, N * sizeof(int)).wait();
    // Submit the content to the queue for execution
    my_gpu_queue.submit([&](handler& h) {
        h.parallel_for(range{N}, [=](id<1> item) {
            device_mem[item] *= 2;
        });
    });
   // Wait the computation done
    my_gpu_queue.wait();
   // Copy back from GPU to CPU
    my_gpu_queue.memcpy(host_mem, device_mem, N * sizeof(int)).wait();
```

```
printf("\nMalloc Host & Device Results:\n");
    for (int i = 0; i < N; i++) {
        printf("%d, ", host_mem[i]);
    printf("\n");
    free(host_mem, my_gpu_queue);
    free(device_mem, my_gpu_queue);
    auto end = std::chrono::high_resolution_clock::now();
    std::cout << "Malloc Host & Device Execution Time: "</pre>
              << std::chrono::duration<double, std::milli>(end -
start).count() << " ms\n";</pre>
void test_malloc_shared(queue& my_gpu_queue) {
    auto start = std::chrono::high_resolution_clock::now();
    int* shared_mem = malloc_shared<int>(N, my_gpu_queue);
   // Init data
    for (int i = 0; i < N; i++) {
        shared_mem[i] = i;
   // Submit task to the queue
    my_gpu_queue.submit([&](handler& h) {
        h.parallel_for(range{N}, [=](id<1> item) {
            shared_mem[item] *= 2;
        });
    });
    // Wait the computation done
    my_gpu_queue.wait();
    printf("\nMalloc Shared Results:\n");
```

```
for (int i = 0; i < N; i++) {
        printf("%d, ", shared_mem[i]);
    printf("\n");
    free(shared_mem, my_apu_queue);
    auto end = std::chrono::high_resolution_clock::now();
    std::cout << "Malloc Shared Execution Time: "</pre>
               << std::chrono::duration<double, std::milli>(end -
start).count() << " ms\n";</pre>
int main() {
    queue my_gpu_queue(sycl::gpu_selector_v);
    std::cout << "Selected GPU device: "</pre>
               ~
my_gpu_queue.get_device().get_info<info::device::name>() << "\n";</pre>
    test_malloc_host_device(my_gpu_queue);
    test_malloc_shared(my_qpu_queue);
    return 0;
}
```

可以看到结果确实共享内存更高效

```
D:\Code\GitCode\oneAPI_course\code>icx-cl -fsycl -fsycl-targets=nvptx64-nvidia-cuda test_shared_mem.cpp -o test_shared_mem.exe
Intel(R) oneAPI DPC++/C++ Compiler for applications running on Intel(R) 64, Version 2025.0.0 Build 20241008
Copyright (C) 1985-2024 Intel Corporation. All rights reserved.

D:\Code\GitCode\oneAPI_course\code>test_shared_mem.exe
Selected GPU device: NVIDIA GeForce RTX 4070 Ti SUPER

Malloc Host & Device Results:
0, 2, 4, 6, 8, 10, 12, 14, 16, 18,
Malloc Shared Results:
0, 2, 4, 6, 8, 10, 12, 14, 16, 18,
Malloc Shared Execution Time: 42.7996 ms

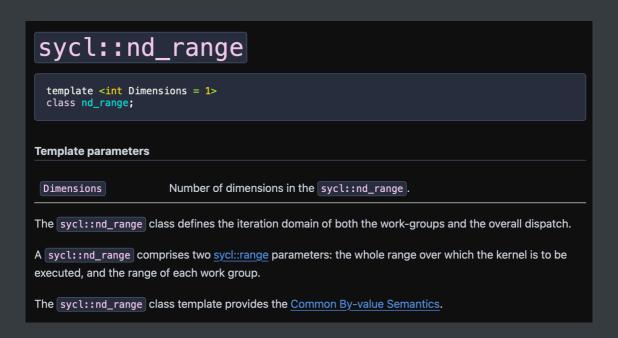
D:\Code\GitCode\oneAPI_course\code>%
```

任务3

创建一个新文件(vector_add.cpp),使用ND_range实现一个向量加法程序

nd_range

首先我们查看什么是nd_range



据此我们可以得知,通过两个 sycl::range 参数, sycl::nd_range 可以表示如何将整个计算任务分解成多个工作组,以及每个工作组内部的任务如何分配和调度。

代码实现

接下来我们来开始完成代码。

我们选用的方案是,分配host和device内存,拷贝数据后进行运算,最后将结果拷贝回来并释放内存。这里我们按序初始化了向量用于vector_add的运算。

```
#include <sycl/sycl.hpp>
#include <iostream>
using namespace sycl;

constexpr int N = 1024; // 向量的大小
```

```
int main() {
   // 创建队列,选择 GPU 设备
   queue my_gpu_queue(sycl::gpu_selector_v);
   std::cout << "Selected GPU device: " <<</pre>
       my_qpu_queue.get_device().get_info<info::device::name>() <</pre>
   // 在主机上创建并初始化向量
   int *A = malloc_host<int>(N, my_gpu_queue);
   int *B = malloc_host<int>(N, my_qpu_queue);
   int *C = malloc_host<int>(N, my_gpu_queue);
   for (int i = 0; i < N; i++) {
       A[i] = i; // 向量A的元素初始化为索引值
       B[i] = 2*i; // 向量B的元素初始化为2倍的索引值
   }
   // 在设备上分配内存
   int *d_A = malloc_device<int>(N, my_apu_queue);
   int *d_B = malloc_device<int>(N, my_apu_queue);
   int *d_C = malloc_device<int>(N, my_apu_queue);
   // 将数据从主机传输到设备
   my_gpu_queue.memcpy(d_A, A, N * sizeof(int)).wait();
   my_gpu_queue.memcpy(d_B, B, N * sizeof(int)).wait();
   // 定义工作组大小和全局工作大小
   size_t local_size = 256; // 每个工作组中的元素数
   size_t global_size = N; // 全局工作项数量
   // 使用ND_range提交向量加法计算
   my_gpu_queue.submit([&](handler& h) {
       // 设置设备内存的访问权限
       h.parallel_for<nd_range<1>>(nd_range<1>(global_size,
local_size), [=](nd_item<1> item) {
```

```
// 获取当前工作项的索引
       size_t idx = item.get_global_id(0);
       if (idx < N) { // 确保索引在合法范围内
           d_C[idx] = d_A[idx] + d_B[idx]; // 向量加法
   });
});
// 等待GPU计算完成
my_gpu_queue.wait();
// 将结果从设备拷贝回主机
my_gpu_queue.memcpy(C, d_C, N * sizeof(int)).wait();
// 输出结果
std::cout << "First 10 elements of the result vector C:\n";</pre>
for (int i = 0; i < 10; i++) {
   std::cout << C[i] << ", ";
std::cout << "\n";
// 释放内存
free(A, my_gpu_queue);
free(B, my_gpu_queue);
free(C, my_gpu_queue);
free(d_A, my_gpu_queue);
free(d_B, my_gpu_queue);
free(d_C, my_gpu_queue);
return 0;
```

完成vector_add。

Part 2 课后作业

作业1

改写gemm_basic代码26、27行,利用work group和local work item的坐标来计算global坐标

代码改写

我们修改代码,将原本的直接调用 get_global_id() 修改为计算 group_id*block_size+local_id 得到即可

```
// 获取当前局部工作项和工作组的坐标
int local_row = index.get_local_id(0);
int local_col = index.get_local_id(1);
int group_row = index.get_group(0);
int group_col = index.get_group(1);

// 计算全局坐标
int row = group_row * block_size + local_row;
int col = group_col * block_size + local_col;
```

测试代码

修改后编译发现, 存在报错

第一处报错 fabs 存在歧义, 我们修改为 std::fabs 。

第二出为 cl::sycl 已经被改为 sycl ,修改即可。

编译并运行

```
D:\Code\GitCode\oneAPI_course\code>icx-cl -fsycl -fsycl-targets=nvptx64-nvidia-cuda gemm_basic_global.cpp -o gemm_basic_global.exe
Intel(R) oneAPI DPC++/C++ Compiler for applications running on Intel(R) 64, Version 2025.0.0 Build 20241008
Copyright (C) 1985-2024 Intel Corporation. All rights reserved.

D:\Code\GitCode\oneAPI_course\code>gemm_basic_global.exe
Problem size: c(1024, 1024) = a(1024, 1024) * b(1024, 1024)

Performance Flops = 2147483648.000000,
GU Computation Time = 11. 613884 (ms);
CPU Computation Time = 585.660242 (ms);

D:\Code\GitCode\oneAPI_course\code>
```

可以看到我们成功完成作业1

作业2

修改程序输入数据的大小,设定为M=N=K=2000,修改程序,并使其通过正确性测试。

代码改写

只需改写输入的mnk即可

测试代码

```
D:\Code\GitCode\oneAPI_course\code>icx-cl -fsycl -fsycl-targets=nvptx64-nvidia-cuda gemm_basic_global.cpp -o gemm_basic_global.exe
[Intel(R) oneAPI DPC++/C++ Compiler for applications running on Intel(R) 64, Version 2025.0.0 Build 20241008
Copyright (C) 1985-2024 Intel Corporation. All rights reserved.

D:\Code\GitCode\oneAPI_course\code>gemm_basic_global.exe
Problem size: c(2000, 2000) = a(2000, 2000) * b(2000, 2000)

Performance Flops = 16000000000.000000,
GPU Computation Time = 84.174252 (ms);
CPU Computation Time = 2754.480908 (ms);

D:\Code\GitCode\oneAPI_course\code>
```

成功完成,我们可以发现,GPU在大规模的矩阵运算上有着明显的优势。